INFORME DE AVANCE EN LA RASPBERRY PI 5

YURA — Robot interactivo para la práctica del idioma quechua

Informe N.º 002 · 08/10/2026

Alcance: traslado a la Raspberry Pi 5, escucha (Vosk y Whisper), conversación, diccionario, voz de Sofía y cuerpo ESP32 (03/10 al 08/10/2026)

Trabajo realizado con Claude Code
para el equipo del proyecto YURA — Cochabamba, Bolivia

Índice

Avance en la Raspberry Pi 5 — 03/10/2026 al 08/10/2026 **3**

0. Cambio de equipo: de computadora de escritorio a Raspberry Pi 5 . . . 3
1. Instalación en la Raspberry Pi 5 . . . 3
2. Reconocimiento de voz (escuchar) . . . 3
3. Modo castellano / quechua y diccionario . . . 4
4. Conversación . . . 4
5. Voz de Sofía (hablar) . . . 4
6. Tiempo de respuesta . . . 5
7. Cuerpo (ESP32) . . . 5
8. Comparación de reconocedores: Whisper y Vosk, antes y ahora . . . 5

Avance en la Raspberry Pi 5 — 03/10/2026 al 08/10/2026

Continúa `correcciones_informe_2026-09-30.md`. Periodo: traslado de Yura de la computadora de escritorio (Ubuntu, GPU NVIDIA) a la Raspberry Pi 5 (8 GB, Raspberry Pi OS sobre Debian 13, Python 3.13) y entrenamiento de escucha, conversación y voz en ese equipo. Todas las cifras se midieron en la Raspberry; las evidencias están en `documentacion_pruebas/evidencias/20_` a `24_`.

0. Cambio de equipo: de computadora de escritorio a Raspberry Pi 5

	Antes (hasta 03/10/2026)	Ahora
Equipo	Computadora de escritorio	Raspberry Pi 5
Procesador	Intel Core de 10.ª generación (las evidencias registran «Intel(R) Core(TM) i3-10100»; por confirmar con el equipo, que lo recuerda como i5)	ARM Cortex-A76, 4 núcleos, 2,4 GHz
Memoria	16 GB	8 GB
Tarjeta gráfica	NVIDIA GTX 1650 (CUDA)	Ninguna utilizable para IA
Sistema	Ubuntu 24.04, Python 3.12, GNOME	Raspberry Pi OS (Debian 13), Python 3.13, labwc
Reconocedor en clase	Whisper small en la GPU	Vosk en la CPU
Audio	Audífonos USB C-Media + televisor por HDMI	Tarjeta de sonido USB C-Media (micrófono y parlante)
Pantalla	Televisor por HDMI	Televisor 4K o pantalla de 1024x600, ajuste automático

Consecuencia principal: sin GPU, Whisper deja de ser viable para escuchar en tiempo real, y el reconocimiento pasa a Vosk. Todo el aprendizaje de la sección 2 sirve para que Vosk recupere lo que daba Whisper small con la GPU.

1. Instalación en la Raspberry Pi 5

- Se recreó el entorno `.venv` (el copiado era de Python 3.12 para x86 y no servía). `torch` se instaló en su versión solo CPU (`torch==2.14.0+cpu`); la versión por defecto de PyPI para ARM64 descargaba varios GB de bibliotecas CUDA inútiles sin GPU. Se instalaron `portaudio19-dev` y `espeak-ng`.
- Arranque automático (servicio de usuario y pantalla en Firefox) verificado con el escritorio labwc de la Pi.
- Audio: tarjeta de sonido USB C-Media (micrófono y parlante). Un primer puerto USB fallaba con error -71 junto con avisos de bajo voltaje de la fuente; en otro puerto funcionó.
- Pantalla: nuevo script `scripts/yura-ajustar-pantalla.py`, que al iniciar sesión elige la resolución según la pantalla conectada (1920x1080 en un televisor 4K; resolución nativa en pantallas menores; probado con 3840x2160 y 1024x600).
- Guía y lista de verificación en `RASPBERRY_PI5.md`.

2. Reconocimiento de voz (escuchar)

Elección del reconocedor. Con las 121 grabaciones reales de la docente:

Reconocedor	Palabras entendidas	Tiempo por audio
Vosk (modelo pequeño en castellano)	89-90 %	0,6 s
Whisper tiny	52 %	3,6 s

Se mantiene Vosk (`YURA_ASR=vosk`). Whisper small solo se usa como verificador en el afinado de pronunciación, no para escuchar en clase.

Aprendizaje de Vosk.

- Las grabaciones de la docente se volvieron a escuchar con Vosk (`aprender_de_audios.py --vosk`); lo aprendido antes era de Whisper y Vosk escribe distinto.

- Se agregaron 7 variaciones por grabación para imitar otras voces (aguda, muy aguda, grave, rápida, lenta, con ruido, aguda con ruido): 1.331 escuchas aprendidas en total. Medido con variaciones distintas a las del entrenamiento (`medir_escucha_vosk.py`), el promedio pasó de 38 % a 47 %; voz grave 37→50 %, rápida y aguda 22→36 %, aula ruidosa 34→41 %. La voz de niño solo subió de 6 % a 14 %.
- «Apágate» no existe en el vocabulario de Vosk (lo escribe «gate», «para date», «apaga te»). Se mapearon esas formas y se probó con 5 voces sintéticas y con la voz del equipo; la orden pide confirmación con «sí» antes de apagar. Se agregó un entrenamiento de órdenes con la voz de quien usa a Yura (`entrenar_ordenes.py`), que solo guarda una forma cuando Vosk la escribió igual al menos 2 veces.
- Preguntas: `aprender_preguntas_vosk.py` dijo con 4 voces «¿Qué significa ___?» y «¿Cómo se dice ___ en quechua?» para cada palabra del diccionario y aprendió 431 formas. Preguntas bien respondidas, de 10/16 a 25/30.

3. Modo castellano / quechua y diccionario

- El afinado de Vosk convertía palabras castellanas en quechuas dentro de frases («traduce agua» → «Aywa»; «desde que» → «desde Wawqi»). Ahora separa la parte castellana («¿cómo se dice **agua**?», no se toca) de la quechua («¿qué significa **allqu**?», se busca en el diccionario). Corrige además «en que hecho» → «en quechua», «vive los» → «dime los».
- Listas por tema desde el diccionario de la base de datos: «los números del uno al nueve», colores, animales, familia, partes del cuerpo, etc., con continuación al decir «sí» o «más». Antes Yura respondía que no tenía esa información.
- Búsqueda por familia de palabras: «plata» → plateado (Qullqi), «perrito» → perro.
- «Quiero que me digas…» y «puedes decirme…» se entienden como «¿cómo se dice…?».

4. Conversación

- «Háblame en español» deja a Yura en modo bilingüe hasta «háblame en quechua» (antes valía solo una respuesta).
- Modo docente: «soy la profesora…», «para mi clase» (y la forma «estoy el docente» que escribe Vosk) dan ideas de actividades en español y se mantienen 5 minutos. Probado con Groq: propuso «caza de colores», «el cajón mágico» y «palabras escondidas».
- Groq (modelo `openai/gpt-oss-120b`) recibe siempre la base conversacional del diccionario (saludos, diálogo infantil, pronombres, preguntas) y debe armar sus frases con ella. Palabras quechuas de sus respuestas presentes en el diccionario: de 26 % a 61 % (10 frases de prueba; el resto son mayormente conjugaciones válidas no escritas en la base). Adivinanzas en español con respuesta del diccionario, para no inventar quechua.
- Respuestas del diccionario variadas por palabra, con invitación a seguir («¿Me la repites?», un reto con otra palabra del mismo tema). Cuando Yura enseña una palabra, durante 30 s compara lo que diga el estudiante con ella y lo felicita o lo anima a repetir.
- Práctica: solo empieza con un pedido («quiero practicar»), no al mencionar «jugar»; una frase normal en medio de la práctica la termina. Se corrigió que 10 de las 303 palabras no podían acertarse nunca («Sulpayki», «Ari», «Para», «Tupananchiskama», etc.).
- Las correcciones de las secciones 3 y 4 salieron de dos sesiones observadas en vivo con el equipo (transcripciones visibles solo con `YURA_DEBUG=1`, desactivado al terminar).

5. Voz de Sofía (hablar)

- Pronunciación: el afinado (`afinar_pronunciacion.py`) ahora parte de lo ya guardado y solo lo reemplaza si queda al menos 3 % más parecido a la docente. La primera corrida en la Pi había reemplazado una escritura oficial de Laime; se detuvo y se restauró. Resultado: 6 escrituras nuevas aceptadas; una segunda corrida de 10 rondas no encontró mejoras.
- Expresión (`voz_sofia.py`): se conservan «?» y «!» (antes se cambiaban por puntos) y la velocidad y el tono varían al celebrar, consolar y preguntar.

- Sin internet: la caché de frases pasó de 499 (21 %) a las 2.986 frases que Yura dice sin internet (100 %). Sin internet Yura ya no espera hasta 40 s a Edge TTS; arma frases con oraciones guardadas y anota las que faltan para generarlas cuando vuelva la conexión (`medir_voz_offline.py`).

6. Tiempo de respuesta

Desde que el niño deja de hablar hasta que Yura empieza a sonar:

Caso	Con internet	Sin internet
Diccionario, frase guardada	≈ 1,7 s	≈ 1,7 s
Diccionario, frase nueva	≈ 3,7 s	≈ 1,9 s (voz robótica)
Conversación con Groq	≈ 4,6 s	no disponible

Partes: 1,0 s de silencio, Vosk 0,56 s, decisión 0,005 s, Groq 0,9 s, voz nueva 2,0 s. La meta propuesta de 2,5 s como máximo no se cumple todavía en los casos con frase nueva.

7. Cuerpo (ESP32)

Se integró un ESP32 DevKit V1 por USB: programa con los pines del equipo y órdenes de voz para avanzar, girar, retroceder y detenerse, con un límite de 3 s por movimiento y freno ante obstáculos a menos de 20 cm. Se encontraron tres problemas de hardware: el chip USB CP2102 reiniciaba el ESP32 al abrir el puerto (resuelto abriéndolo sin DTR/RTS); los pines D16 y D17 cuelgan esta placa; y los servos de los brazos, cableados en D34/D35, no podían funcionar porque esos pines solo son de entrada.

A pedido del equipo, el cuerpo se borró y el ESP32 se formateó. Luego, también a su pedido (07/10/2026, en otra sesión de trabajo), se volvió a integrar con el programa v5 y los brazos pasados a D15 y D33. Pines vigentes: sensores Trig/Echo adelante 23/22, izquierda 21/19, derecha 18/5, atrás 4/2; L298N ENA 13, IN1 12, IN2 14, IN3 27, IN4 26, ENB 25; servos D15, D33 y cuello D32. No se probó con motores ni sensores alimentados por la batería.

8. Comparación de reconocedores: Whisper y Vosk, antes y ahora

8.1 Lo que ya está medido

Reconocedor y equipo	Palabras de la docente	Tiempo por frase	Fuente
Whisper small, computadora con GPU (antes)	81 % con lo aprendido (menú 83 %, juego 90 %, sin pistas 71 %)	0,7 s	`evidencias/17_medicion_aprendizaje.txt`
Vosk, Raspberry Pi 5 (ahora)	89-90 %	0,56-0,6 s	sección 2
Whisper tiny, Raspberry Pi 5	52 %	3,6 s	sección 2

Las dos primeras filas no se midieron de la misma forma: en la computadora, el 81 % se calculó sin usar lo aprendido de la misma grabación y con tres tipos de pistas; en la Pi, el 89-90 % es sobre las 121 grabaciones con el afinado de Vosk. Indican que Vosk en la Pi quedó a un nivel parecido al de Whisper small con GPU para las palabras de la docente, y con tiempo de respuesta parecido; no permiten afirmar que sea mejor.

Whisper small no se usa en la Pi para escuchar: en la CPU es varias veces más lento que tiny (3,6 s por frase) y no cumpliría la meta de 2,5 s. Su tiempo exacto en la Pi no se midió.

8.2 Whisper tiny con el mismo proceso que Vosk (medido el 08/10/2026)

Para que la comparación sea defendible, `entrenar_whisper_tiny.py` dio a Whisper tiny el mismo trato que a Vosk y midió a los dos con la misma prueba: las 121 grabaciones de la docente tal cual y con variaciones distintas a las del entrenamiento (voz de niño, voz grave, aula ruidosa, rápido y agudo), 605 audios. También midió 24 frases en castellano (8 frases, 3 voces) y el tiempo por frase. Lo aprendido por Whisper se guardó aparte y no modificó a Vosk ni lo que usa Yura.

Reconocedor (Raspberry Pi 5)	Palabras (prueba)	Tiempo por frase	Frases en castellano
Vosk + su proceso (lo que usa Yura)	50 %	0,49 s	100 %
Whisper tiny tal cual	37 %	1,26 s	79 %
Whisper tiny + el mismo proceso que Vosk	52 %	1,27 s	79 %
Whisper tiny reentrenado (decodificador, 968 audios, 4 épocas)	97 %	1,19 s	42 %

Lectura:

- Con el mismo proceso, Whisper tiny entiende las palabras un poco más que Vosk (52 % frente a 50 %), pero es 2,6 veces más lento y entiende menos el castellano (79 % frente a 100 %).
- Reentrenado, llega al 97 % en palabras. Ese valor no demuestra que entienda a otras personas: la prueba usa variaciones de las mismas 121 grabaciones con que se reentrenó, así que en buena parte las memorizó (la pérdida del entrenamiento bajó de 1,21 a 0,026). Además olvidó el castellano: cayó de 79 % a 42 %, por lo que no entendería preguntas como «¿cómo se dice perro en quechua?».
- Decisión: Yura sigue con Vosk como reconocedor principal. Es el único que entiende el castellano completo, responde en medio segundo y cumple la meta de tiempo. El modelo reentrenado queda guardado en `basedatos/whisper_tiny_yura.pt` (no se sube a git).
- Posibilidad a probar: usar el Whisper tiny reentrenado solo para las respuestas de una palabra del juego y la práctica, y Vosk para todo lo demás; la respuesta tomaría unos 2,3 s. Antes hay que medirlo con voces que no estén en el entrenamiento (por ejemplo, niños grabados en el modo «Enseñar»).
- El quinto caso previsto (reentrenado y con el proceso) se omitió por tiempo. Durante la medición la Raspberry llegó a 82 °C y se frenó por temperatura, con el ventilador al máximo.

Datos: `evidencias/24_whisper_tiny_vs_vosk.json` y `24_whisper_tiny_vs_vosk.txt`.

Verificación: 357 pruebas aprobadas, incluidas las del cuerpo. Evidencias nuevas: `20_` y `22_` (afinado de pronunciación), `21_` (preguntas Vosk), `23_` (voz sin internet), `24_` (Whisper tiny frente a Vosk).

Límites: la comparación de la sección 8.2 usa las grabaciones de una sola docente; las mediciones de escucha usan grabaciones de una sola docente y voces sintéticas; con niños reales pueden variar, y la voz de niño sigue siendo el punto débil (14 %). El sonido «ch'» se reconoce mal («Ch'uspi» → «spy»). Las respuestas de Groq en quechua no se validaron con hablantes. Pendiente: grabar voces de niños en el modo «Enseñar», validar con la docente, cumplir la meta de 2,5 s y probar el cuerpo con energía.